

# OAI-PMH API

1. 6. 2020

API v současné době nabízí službu *AMCR Data Provider*, která poskytuje metadatové záznamy z databáze AMČR, a to pomocí protokolu *OpenArchives Initiative Protocol for Metadata Harvesting* (OAI-PMH).

Naše implementace protokolu OAI-PMH podporuje reprezentaci metadat ve standardech:

- [Dublin Core](#) – poskytuje část datasetu týkající se dokumentů a jejich popisu;
- ~~CIDOC-CRM~~ – nabízí archivovaná, volně přístupná data z AMČR ve formátu RDF v syntaxi odpovídající této ontologii;
- **AMČR XML** – nativní formát, který umožňuje plné vytěžování databáze při zohlednění přístupových práv.

[Uživatelé](#) s vyšším oprávněním mohou využít své přihlašovací údaje do AMČR pro přístup k nearchivovaným či jinak chráněným záznamům. Aktualizace dat probíhá na denní bázi.

API najdete na adrese <https://api.aiscr.cz>.

## Technické řešení

Architektura API se skládá z 5 komponent: *AMCR Filter*, *RDF Converter*, *Scrub*, *AMCR Pass* a *AMCR Data Provider*. Všechny komponenty jsou napsány v jazyce Java. ~~Řešení používá open-source projekt X3ML Engine pro konverzi XML na RDF.~~

## Řešení filtrace

### Stav a přístupnost záznamu

Přístupnost záznam je ovlivněna jak [procesními stavy](#) daných metadatových záznamů, tak [uživatelskou rolí](#).

## Sety

Selektivní výběr je umožněn pomocí nadefinovaných setů, viz také Obr. 4.



**Archaeological Information System of the Czech Republic**

**Public API**  
 AMCR Data Provider  
 Mgr. Petr Pajdla  
 Institute of Archaeology, Czech Acad Sci, Brno

### Introduction

The Archaeological Information System of the Czech Republic (AIS CR) is a research infrastructure integrating digital resources on Czech archaeology. In our core information system (Archaeological Map of the Czech Republic, AMCR), we collect and curate data on new and past archaeological activities conducted in the Czech Republic. We strive to follow FAIR principles and introduce new digital services for the archaeological community and the general public.

### Public API

The API provides metadata records from the AMCR database in a machine readable format using the Open Archives Initiative Protocol for Metadata Harvesting (OAI-PMH). OAI-PMH implementation supports representation in native AMCR XML, CIDOC-CRM and Dublin Core.

### Example Request

List identifiers of documents that were published between 1st and 28th February 2021 in CIDOC-CRM.

```
https://api.aiscr.cz/dapro/?oai?verb=ListIdentifiers&
  set=dokument& from=2021-02-01& until=2021-02-28&
  metadataPrefix=oai_rdf
```

*click here*

```
<?xml version="1.0" encoding="UTF-8" standalone="no" xmlns:xsi="http://www.w3.org/2001/XMLSchema-instance"
  xmlns="http://www.openarchives.org/OAI/2.0/" xmlns:xsd="http://www.openarchives.org/OAI/2.0/OAI-PMH.xsd">
  <responseDate>2021-02-28T15:18:02Z</responseDate>
  <request verb="ListIdentifiers" metadataPrefix="oai_rdf" from="2021-02-01" until="2021-02-28"
    set="dokument" http://api.aiscr.cz/dapro/oai/request/>
    <listIdentifiers>
      <identifier>https://api.aiscr.cz/id/C-DL-2000000000/</identifier>
      <setSpec>dokument</setSpec>
    </listIdentifiers>
  </response>
  <response>
    <identifier>https://api.aiscr.cz/id/C-DL-0000110000/</identifier>
    <setSpec>dokument</setSpec>
    <timestamp>2021-02-02</timestamp>
    <resumptionToken>0</resumptionToken>
  </response>
  </listIdentifiers>
</OAI-PMH>
```

To get another page, use `resumptionToken=` as a single argument to a given verb.

For more information on the infrastructure, check the Structuring archaeological evidence book by Martin Kuna et al.

### Verbs

- `https://api.aiscr.cz/dapro/oai?verb=`
  - Identify**  
returns information on the repository
  - ListMetadataFormats**  
returns available metadata formats
  - ListIdentifiers**  
returns record headers  
arguments: metadataPrefix  
optional: set, from, until
  - ListRecords**  
returns records  
arguments: metadataPrefix  
optional: set, from, until
  - GetRecord**  
returns individual record  
arguments: metadataPrefix, identifier
  - ListSets**  
lists possible sets

*click the verbs to see example requests*

### Arguments

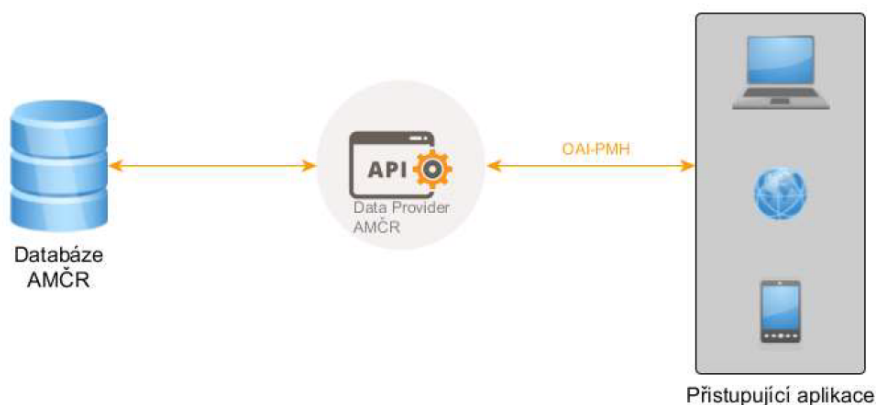
- `metadataPrefix=`
  - oai\_dc
  - oai\_rdf
  - oai\_amcr
  - Dublin Core
  - CIDOC-CRM
  - Native XML
- `identifier=`  
filters based on identifier, see ListIdentifiers
- `set=`  
filters based on sets, see ListSets
- `from=` & `until=`  
date in ISO-8601, i.e. 2021-04-01





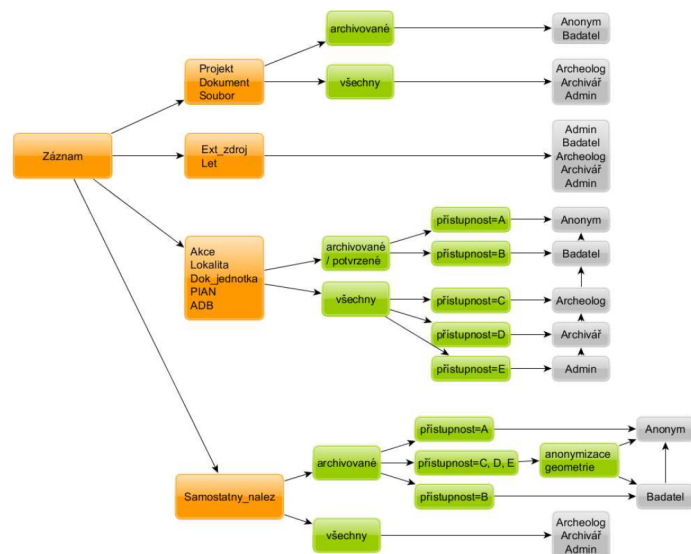


Obr. 1: Poster prezentující API s příklady možných requestů (Pajdla 2021)



Obr. 2: OAI-PMH API a služba AMCR Data Provider





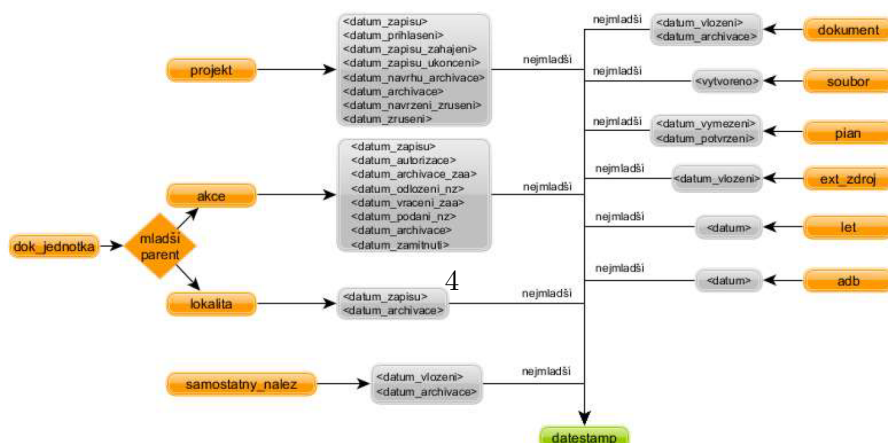
Obr. 5: Schéma přístupnosti záznamů dle uživatelských rolí

Tab. 1: Sety

setSpec	setName
projekt	Projekty / Projects
akce	Akce / Fieldwork Events
lokalita	Lokality / Sites
dok_jednotka	Dokumentační jednotky / Descriptive Units
adb	Archeologický dokumentační bod / Archaeological Documentation Point
dokument	Dokumenty / Documents
soubor	Soubory / Files
pian	PIAN / Spatial Units
ext_zdroj	Externí zdroje / External Sources
let	Lety / Flights
samostatny_nalez	Samostatné nálezy / Individual Finds

## Datestamps

Pro dotazy `ListRecords` a `ListIdentifiers` je umožněno filtrování na základě volitelného argumentu `datestamp` (from – od, until – do), kdy `datestamp` je vždy nejmladší z dostupných datumů.



Obr. 6: Specifikace nastavení datestamp pro jednotlivé záznamy

## Přihlášení

Pokud chcete pro stahování dat používat svůj účet AMČR, je nutné přihlášení pomocí Basic access authentication. Protokol https zajišťuje bezpečnou komunikaci. Způsob přihlášení se liší v každém nástroji, který je pro stahování dat používán. Níže jsou detailněji popsány způsoby přihlášení pro *cURL* a *Postman*.

### cURL

cURL je nástroj skládající se ze softwarové knihovny (libcurl) a z nástroje příkazového řádku (curl) sloužících ke stahování souborů přes počítačovou síť. Nástroj je dostupný pro různé operační systémy Linux, macOS a Windows. Své uživatelské jméno a heslo je možné zadat pomocí přepínače -u.

```
curl -u username:password <GET request>
```

Přihlašovací údaje je nutné posílat v každém requestu.

### Postman

Postman je multiplatformní aplikace pro vývojáře sloužící k návrhu a interakci s HTTP API. Uživatelské jméno a heslo lze zadávat na kartě *Autorizace*. V rozevírací nabídce *TYPE* zvolte možnost *Basic Auth* a stiskněte tlačítko *Odeslat*. Přihlašovací údaje jsou poté posílány automaticky v každém requestu.

## Verbs

Dotazování v protokolu OAI-PMH je možné pomocí tzv. sloves (verbs). Význam jednotlivých sloves s příkladem užití jsou popsány v následujících kapitolách. Podrobná specifikace protokolu OAI-PMH je k dispozici [zde](#).

### Identify

Sloveso *Identify* se používá k získání informací o úložišti.

Dotaz: <https://api.aiscr.cz/dapro/oai?verb=Identify>

## ListMetadataFormats

Sloveso `ListMetadataFormats` se používá k načtení formátů metadat dostupných z úložiště.

Dotaz: <https://api.aiscr.cz/dapro/oai?verb=ListMetadataFormats>

Odpověď:

```
<OAI-PMH xsi:schemaLocation="http://www.openarchives.org/OAI/2.0/ http://www.openarchiv
  <responseDate>2023-07-10T14:10:00Z</responseDate>
  <request verb="ListMetadataFormats">https://api.aiscr.cz/dapro/oai</request>
  <ListMetadataFormats>
    <metadataFormat>
      <metadataPrefix>oai_dc</metadataPrefix>
      <schema>http://www.openarchives.org/OAI/2.0/oai_dc.xsd</schema>
      <metadataNamespace>http://www.openarchives.org/OAI/2.0/oai_dc/</metadataNamespace>
    </metadataFormat>
    <metadataFormat>
      <metadataPrefix>oai_rdf</metadataPrefix>
      <schema>https://api.aiscr.cz/dapro/media/oai_rdf.xsd</schema>
      <metadataNamespace>https://api.aiscr.cz/schema/oai_rdf/</metadataNamespace>
    </metadataFormat>
    <metadataFormat>
      <metadataPrefix>oai_amcr</metadataPrefix>
      <schema>https://api.aiscr.cz/dapro/media/oai_amcr.xsd</schema>
      <metadataNamespace>https://api.aiscr.cz/schema/oai_amcr/</metadataNamespace>
    </metadataFormat>
  </ListMetadataFormats>
</OAI-PMH>
```

Implementace OAI-PMH podporuje reprezentaci metadat v:

- Dublin Core – `metadataPrefix oai_dc`,
- ~~CIDOC CRM – `metadataPrefix oai_rdf`,~~
- interním AMČR XML – `metadataPrefix oai_amcr`.

Jednotlivá schémata jsou k dispozici na: [https://api.aiscr.cz/dapro/media/\\*.xsd](https://api.aiscr.cz/dapro/media/*.xsd).

## ListIdentifiers

Sloveso `ListIdentifiers` se používá pro načtení záhlaví záznamů (header) z úložiště. Povinným argumentem je `metadataPrefix`. Nepovinné argumenty umožňují filtraci záhlaví na základě nastavených [setů](#) a/nebo [datestamp](#). Uživatel dostane v odpovědi první stránku se záhlavím záznamů. Pro načtení dalších stránek je nutné použít [resumptionToken](#).

Dotaz: [https://api.aiscr.cz/dapro/oai?verb=ListIdentifiers&metadataPrefix=oai\\_amcr](https://api.aiscr.cz/dapro/oai?verb=ListIdentifiers&metadataPrefix=oai_amcr)

## ListRecords

Sloveso `ListRecords` se používá pro načtení záznamů z úložiště. Povinným argumentem je `metadataPrefix`. Nepovinné argumenty umožňují filtraci záznamů na základě nastavených [setů](#) a/nebo [datestamp](#). Uživatel dostane v odpovědi první stránku se záznamy. Pro načtení dalších stránek je nutné použít [resumptionToken](#).

Dotaz: [https://api.aiscr.cz/dapro/oai?verb=ListRecords&metadataPrefix=oai\\_amcr](https://api.aiscr.cz/dapro/oai?verb=ListRecords&metadataPrefix=oai_amcr)

Odpověď:

```
<OAI-PMH xsi:schemaLocation="http://www.openarchives.org/OAI/2.0/ http://www.openarchiv
  <responseDate>2023-07-11T07:21:17Z</responseDate>
  <request verb="ListRecords" metadataPrefix="oai_amcr">https://api.aiscr.cz/dapro/oai<
  <ListRecords>
    <record>
      <header>
        <identifier>https://api.aiscr.cz/id/C-201773056</identifier>
        <datestamp>2022-06-09</datestamp>
        <setSpec>projekt</setSpec>
      </header>
      <metadata>
        <oai_amcr:amcr xsi:schemaLocation="https://api.aiscr.cz/schema/oai_amcr https://
          <projekt>
            <ident_cely>C-201773056</ident_cely>
            <stav>6</stav>
            <typ_projektu>záchranný</typ_projektu>
            <datetime_born>2016-01-01 00:00:00</datetime_born>
            <okres>PLZEŇ-SEVER</okres>
            (...)
            <termin_odevzdani_nz>2019-12-30</termin_odevzdani_nz>
            <child_akce>C-201773056A</child_akce>
          </projekt>
        </oai_amcr:amcr>
      </metadata>
    </record>
    <resumptionToken cursor="0" expirationDate="2023-07-12T22:30:00Z">2023-07-10.oai_am
  </ListRecords>
</OAI-PMH>
```

## GetRecord

Sloveso `GetRecord` se používá k získání individuálního záznamu metadat z úložiště. Požadované argumenty jsou `metadataPrefix` a identifikátor položky (`identifier`), ze které je záznam požadován. Položky jednotlivých setů nesou v hlavičce persistentní

identifikátory, odvozované z pole *ident\_cely* u jednotlivých záznamů nejvýše v XML struktuře záznamu v daném setu. Výjimkou je set soubor, kde jako identifikátor slouží pole *filepath*. K základnímu formátu identifikátoru je vždy jako prefix připojena URL: <https://api.aiscr.cz/id/>. Odkazy mezi záznamy napříč sety jsou řešeny na úrovni základního identifikátoru bez prefixu. Další informace ke struktuře identifikátorů a vazbám naleznete v samostatné kapitole.

Dotaz: [https://api.aiscr.cz/dapro/oai?verb=GetRecord&identifier=https://api.aiscr.cz/id/C-DL-200400001&metadataPrefix=oai\\_amcr](https://api.aiscr.cz/dapro/oai?verb=GetRecord&identifier=https://api.aiscr.cz/id/C-DL-200400001&metadataPrefix=oai_amcr)

Odpověď:

```
<OAI-PMH xsi:schemaLocation="http://www.openarchives.org/OAI/2.0/ http://www.openarchiv
  <responseDate>2023-07-11T07:37:18Z</responseDate>
  <request verb="GetRecord" metadataPrefix="oai_amcr" identifier="https://api.aiscr.cz/
  <GetRecord>
    <record>
      <header>
        <identifier>https://api.aiscr.cz/id/C-DL-200400001</identifier>
        <datestamp>2018-06-15</datestamp>
        <setSpec>dokument</setSpec>
      </header>
      <metadata>
        <oai_amcr:amcr xsi:schemaLocation="https://api.aiscr.cz/schema/oai_amcr https://
          <dokument>
            <ident_cely>C-DL-200400001</ident_cely>
            <let>C-LET-00253</let>
            (...)
            <jednotka_dokumentu>
              <ident_cely>C-DL-200400001-D01</ident_cely>
              (...)
              <komponenta_dokumentu>
                <ident_cely>C-DL-200400001-K01</ident_cely>
                <parent>C-DL-200400001-D01</parent>
                <obdobi>pr.zem</obdobi>
                <areal>sídliště nesp.</areal>
                <aktivita_sidlistni>1</aktivita_sidlistni>
                <aktivita_pohrebni>0</aktivita_pohrebni>
                (...)
                <nalez_dokumentu>
                  (...)
                </nalez_dokumentu>
              </komponenta_dokumentu>
            </jednotka_dokumentu>
          </dokument>
        </oai_amcr:amcr>
```



```
</metadata>
</record>
</GetRecord>
</OAI-PMH>
```

## ListSets

Sloveso **ListSets** se používá k načtení nastavené struktury úložiště, tzv. setů.

Dotaz: <https://api.aiscr.cz/dapro/oai?verb=ListSets>

## Parametry

### Stránkování

Pomocí sloves uživatel získává první stránku požadovaných metadat. Pro získání dalších záznamů je nutné použít parametr **resumptionToken**, který uživatel dostal v odpovědi na svůj dotaz. Parametr **resumptionToken** je vždy na konci odpovědi. Počet záznamů na stránku je dán konfigurací na straně poskytovatele API.

Odpověď na dotaz v sekci [ListRecords](#) vrátila následující XML element obsahující **resumptionToken**, který je použit v dalším dotazu:

```
<resumptionToken cursor="0" expirationDate="2023-07-12T22:30:00Z">
  2023-07-10.oai_amcr.1000.projekt.1000.1000...f
</resumptionToken>
```

Dotaz: [https://api.aiscr.cz/dapro/oai?verb=ListIdentifiers&resumptionToken=2023-07-10.oai\\_amcr.1000.projekt.1000.1000...f](https://api.aiscr.cz/dapro/oai?verb=ListIdentifiers&resumptionToken=2023-07-10.oai_amcr.1000.projekt.1000.1000...f)

Parametr **resumptionToken** je v tomto případě společně se slovesy **ListRecords** a **ListIdentifiers** výhradním parametrem.

### Filtrování

Tzv. selektivní sklizeň umožňuje uživatelům omezit požadavky na sběr dat na části metadat dostupných z úložiště. OAI-PMH podporuje selektivní sklizeň se dvěma typy kritérií pro sklizeň, která mohou být kombinována: **datestamp** a **set**. Data provider AMČR navíc uživatelům filtruje záznamy podle jejich přístupnosti.

## Podle přístupnosti záznamu

Při zpracování dotazu jsou uživateli automaticky záznamy filtrovány podle přístupnosti, která je nadefinovaná v AMČR. Anonymní uživatel má vždy přístupnost pouze k archivovaným záznamům. Archeologové či uživatelé s vyšším oprávněním mají přístup i k nearchivovaným či jinak chráněným záznamům. Více viz kapitoly k [procesním stavům](#) a [uživatelským rolím](#).

## Pomocí Setů

Protokol OAI-PMH umožňuje filtrování pomocí nadefinovaných setů, a to přidáním parametru `set`. Pomocí slovesa `ListSets` je možné získat hodnotu `setSpec` pro všechny nadefinované [sety](#), viz také Obr. 4. Pro zvolené filtrování se poté do requestu se slovesy `ListRecords` nebo `ListIdentifiers` přidává parametr `set=setSpec`. Filtrování pomocí setů lze kombinovat s filtrováním pomocí `datestamp`.

Dotaz: [https://api.aiscr.cz/dapro/oai?verb=ListRecords&set=akce&metadataPrefix=oai\\_amcr](https://api.aiscr.cz/dapro/oai?verb=ListRecords&set=akce&metadataPrefix=oai_amcr)

## Pomocí datestamp

Protokol OAI-PMH umožňuje filtrování pomocí datumu (`datestamp`), přiřazeného ke každému záznamu. Pro požadované filtrování se poté do requestu se slovesy `ListRecords` nebo `ListIdentifiers` přidává parametr `from` (od) a/nebo `until` (do).

Dotaz: [https://api.aiscr.cz/dapro/oai?verb=ListIdentifiers&metadataPrefix=oai\\_amcr&from=2022-12-10&until=2022-12-20](https://api.aiscr.cz/dapro/oai?verb=ListIdentifiers&metadataPrefix=oai_amcr&from=2022-12-10&until=2022-12-20)

Pajdla, P. 2021 *AIS CR Public API: AMCR Data Provider*.